

MEĐIMURSKO VELEUČILIŠTE U ČAKOVCU
STRUČNI STUDIJ RAČUNARSTVO

KRISTIJAN FIŠTREK

MODEL NEURO-FUZZY SUSTAVA ZA PROCJENU ZAPOS LJIVOSTI
STUDENATA MEV-A

ZAVRŠNI RAD

ČAKOVEC, 2017.

MEĐIMURSKO VELEUČILIŠTE U ČAKOVCU
STRUČNI STUDIJ RAČUNARSTVO

KRISTIJAN FIŠTREK

MODEL NEURO-FUZZY SUSTAVA ZA PROCJENU ZAPOS LJIVOSTI
STUDENATA MEV-A

*SYSTEM BASED ON NEURO-FUZZY MODEL FOR EMPLOYMENT
ESTIMATION OF MEV STUDENTS*

ZAVRŠNI RAD

Mentor :

mr. sc. Željko Knok, dipl. ing.

ČAKOVEC, 2017.

Zahvala,

zahvaljujem se svojem mentoru Željku Knoku na trudu i uloženom vremenu, na konzultacijama, stručnim savjetima i prijedlozima koji su pomogli pri izradi i dovršavanju ovoga završnoga rada.

Posebno se zahvaljujem svojoj obitelji i prijateljima, koji su uvijek bili uz mene pružajući mi podršku, razumijevanje i potrebnu pomoć prilikom studiranja.

SAŽETAK

U ovome završnom radu prezentirane su tehnike izrade i mogućnosti modela na bazi neuronskih mreža, izrađen pomoću MATLAB softverskog paketa. Za izradu modela koristiti će se Neural Network Toolbox alatni paket koji omogućuje kreiranje i manipulaciju nad umjetnim neuronskim mrežama pomoću grafičkog sučelja ili naredbama pomoću komadnog prozora.

Rad je podijeljen na dva dijela. Prvi dio se bavi općenitim informacijama o neuronskom računarstvu. Pruža se kratak uvod u povijest neuronskih mreža, ciljeve i postignuća neuronskog računarstva te se daje usporedba biološke i umjetne neuronske mreže. Drugi dio prikazuje konkretnije probleme koji su se pokušavali riješiti prilikom izrade ovoga rada. Jedan od takvih problema je priprema podataka. U ovome segmentu naglasiti će se važnost kvalitetnih podataka te demonstrirati tehnike korištene prilikom same pripreme prikupljenih podataka. Zatim slijedi određivanje i podjela podataka prema zahtjevima umjetne neuronske mreže. Objasniti će se nužnost podjele, na što se dijele podaci te u koje svrhe. Nakon pripremljenih podataka, bitno je odrediti paradigmu učenja po kojoj će se kreirati mreža trenirati. Obrazložiti će se zbog čega je odabrana supervizijska paradigma te će se objasniti njene prednosti i nedostaci u usporedbi sa ostalima. Nakon toga slijedi određivanje arhitekture mreža. Također će se objasniti zašto definirane strukture funkcioniraju u kontekstu ovoga rada. Unutar MATLAB sučelja, kreiranje mreža se može izvršiti na više načina. Ovdje će se prezentirati izrada neuronske mreže pomoću grafičkog sučelja i programskog koda te će se usporediti njihove razlike. Upravo izrada preko grafičkog sučelja služila je kao tehnika kojom su se modelirale sve neuronske mreže u ovome završnome radu. Iako prezentirane performanse i rezultati tih mreža nisu krajnji, oni su poslužili kao startna točka za daljnja treniranja i testiranja mreža.

Naposljetku, predstaviti će se dobiveni rezultati na temelju pripremljenih podataka i određenoj arhitekturi za mreže trenirane na podacima pojedinačnih smjerova te neuronskoj mreži treniranoj na temelju cjelokupnog veleučilišta.

Ključne riječi : MATLAB, neuronske mreže, testiranje, priprema podataka, supervizijska paradigma

SADRŽAJ

1. UVOD	6
2. CILJ I DOPRINOS ZAVRŠNOG RADA.....	7
3. NEURONSKE MREŽE	8
3.1. Povijest Neuronskih Mreža	8
3.2. Neuronsko Računarstvo	9
3.3. Razlika biološke i umjetne neuronske mreže	10
4. IZRADA MODELA.....	11
4.1. Pretprocesiranje podataka	12
4.2. Podjela podataka	14
4.3. Pravilo učenja.....	14
4.4. Arhitektura Mreža	15
4.4.1.Mreže za pojedinačne smjerove	15
4.4.2. Mreža za cijelo veleučilište	15
4.5. Kreiranje neuronskih mreža	16
4.5.1.Kreiranje neuronske mreže pomoću GUI-a.....	18
4.5.1.Kreiranje neuronske mreže pomoću programskog koda	24
4.6. Rezultati	27
4.6.1. Neuronska mreža za smjer računarstva	27
4.6.2. Neuronska mreža za smjer menadžmenta	28
4.6.3. Neuronska mreža za smjer održivog razvoja.....	30
4.6.4. Neuronska mreža na razini veleučilišta.....	31
5. ZAKLJUČAK	32
6. LITERATURA.....	33
7. PRILOG A : PODACI.....	34
7.1. Prilog A-1	34
7.2. Prilog A-2.....	35
7.3. Prilog A-3	38

1. UVOD

Funkcije ljudskog mozga su stoljećima predstavljali proces vrijedan divljenja. Informacije, koje se u obliku električnih impulsa skupljaju preko naših osjetila, nevjerojatnom se brzinom obrađuju i analiziraju u našem mozgu. Takva efikasna, temeljita i brza obrada podataka bila je izvorna ideja za kreiranje „umjetne neuronske mreže“, koja je težila modeliranju biofiziologije ljudskog mozga. Sustav baziran na principu „umjetnih neuronskih mreža“ trebao bi biti barem donekle sposoban obrađivati informacije i simulirati funkcije prave neuronske mreže, ljudskog mozga. Umjetna se mreža, poput prave, trenira određenom količinom ulaznih informacija, koje se pomoću umjetnih neurona propagiraju po mreži. Umjetni neuron je zamišljen kao jednostavni segment mreže koji prima informacije, obrađuje ih i prosljeđuje ostalim neuronima. Zadatak je da se svojim rezultatom nakon obrade, spostupnom promjenom svojih parametara, približi željenom rezultatu.

Danas se sustavi bazirani na takvim principima koriste u rješavanju raznih problema, od prepoznavanja uzoraka, aproksimacije pa sve do predikcije i analize podataka. Njihova struktura i kompleksnost je ovisna o vrsti problema i željenoj namjeni pa se mogu kategorizirati na više načina. Mreža koja se pokazala najefikasnijom za rješavanje problema u ovome radu sadrži tri zasebna sloja – ulazni, skriveni i izlazni sloj. Bitno je napomenuti da se ulazni sloj ne smatra zasebnim slojem te samim time ne ulazi u definiranje slojevitosti mreže. Razlog tome je taj što ne posjeduje funkciju sume, prijelaznu ili aktivacijsku funkciju, što su jedne od temeljnih karakteristika umjetnih neurona.

U ovome radu opisati će se sve od pripreme podataka do samoga treniranja neuronske mreže u svrhu analize podataka i predikcije zaposlivosti studenata Međimurskog veleučilišta. Poblje će se objasniti vrsta neuronske mreže koja je korištena, vrsta prostiranja signala, način učenja te algoritam povratnog prostiranja pogreške (eng. *Error Backpropagation Algorithm*). Na kraju slijedi usporedba podataka pojedinih neuronskih mreža i konkretnije objašnjenje zadovoljavajućeg ishoda.

2. CILJ I DOPRINOS ZAVRŠNOG RADA

Cilj ovoga rada je izrada inteligentnog sustava koji korištenjem tehnologije umjetnih neuronskih mreža služi za analizu i procjenu zaposlivosti studenata. Sustav bi u konačnici trebao biti sposoban da na temelju pripremljenih ulaznih parametara pruži odgovarajuće izlazne podatke koji bi služili kao rezultati točne procjene. Kako bi jedan ovakav sustav mogao pravilno funkcionirati, potrebno ga je opskrbiti s kvalitetnim izvornim podacima. Pošto su ulazni parametri ključni faktor u izradi i ispravnom funkcioniranju inteligentnog sustava, u radu će se naročito fokus usmjeriti prema pripremi prikupljenih podataka. Prilikom izrade zadovoljavajućeg sustava, pridodat će se posebna pažnja demonstraciji alata MATLAB softverskog paketa. Prezentirati će se mogućnosti izrade umjetne neuronske mreže pomoću grafičkog sučelja i programskog koda te usporediti njihovi rezultati.

Osim samog modeliranja inteligentnog modela, svrha ovoga rada je također predstaviti tehnologiju i prezentirati faze izrade sustava neuronskih mreža, upoznati programere sa tehnikama pripreme podataka što je potrebno za izradu jednog inteligentnog sustava te im približiti alate kojima mogu ostvariti svoje ideje. Istraživanjem i primjenom tehnologija u ovome radu želi se osigurati startna točka i bazna ideja na kojoj bi se temeljila daljnja istraživanja i eventualno poboljšao model predstavljen u nastavku rada.

3. NEURONSKE MREŽE

3.1. Povijest Neuronskih Mreža

Neuropsiholog Warren McCulloch i, tada mladi matematičar, Walter Pitts napisali su 1943. godine znanstveni rad u kojemu su iznijeli hipoteze o radu neurona. Kako bi što bolje objasnili i predstavili svoja mišljenja, modelirali su jednostavnu neuronsku mrežu pomoću električnih krugova. Koncept rada neurona bio je potvrđen 1949. godine kada je Donald Hebb predstavio svoju knjigu „*Organization of Belief*” u kojoj se izjasnio da je serija neurona povezana zajedno, ojačana pri svakom korištenju.

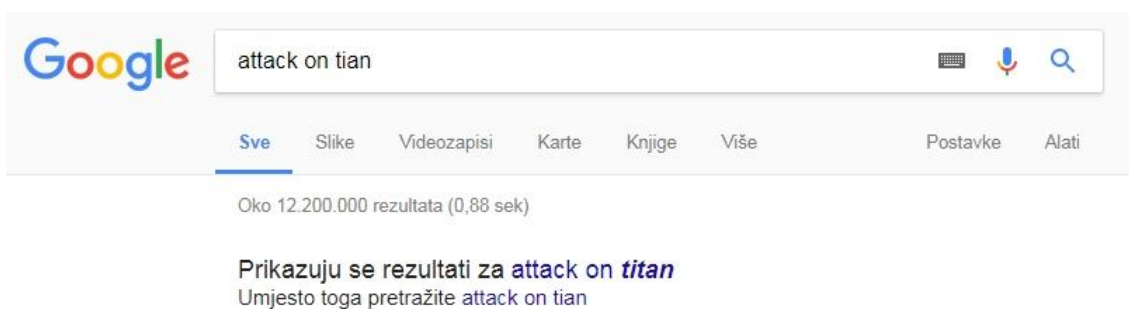
Nathaniel Rochester, jedan od pionira programerskog inženjerstva, napravio je prvi korak prema modeliranju i simuliranju konstruktivnijih neuronskih mreža. Iako su njegovi prvi pokušaji završili neuspješno, poslužili su kao motivacija i odskočna daska za buduća istraživanja. Rochesterovim stopama krenuli su Bernard Widrow i Marcian Hoff, sa Stanford sveučilišta, te razvojem LSM algoritam (eng. *Least Mean Squares Filter Algorithm*) uspješno modelirali neuronske mreže zvane ADALINE i MADALINE koje su radile sa tehnikom algoritma povratnog prostiranja pogreške. MADALINE – nazvana po korištenju višestrukih adaptivnih linearnih elemenata (eng. *Multiple ADaptive, LINear Elements*) je bila prva neuronska mreža koja je bila primijenjena na problem iz stvarnog života. Služila je kao adaptivni filter za eliminiranje jeke na telefonskim linijama i do danas je u komercijalnoj upotrebi [1].

Nije trebalo dugo da mitovi nađu svoje mjesto u literaturi toga vremena te omoguće uspon piscima poput Isaac Asimova, koji je zapamćen po svojim legendarnim zakonima robotike. Strah, kombiniran sa zbunjenošću, izazvao je oštre kritike ljudi prema bilo kakvim istraživanjima temeljenim na principima neuronskih mreža. Takav stav je rezultirao zaustavljanjem financiranja projekata i usporio rast istraživanja sve do početka 80-ih godina, točnije sve do 1982. godine, kada je interes ponovno bio pobuđen konferencijom u Japanu i John Hopfieldovim znanstvenim radom. Neuroračunarstvo je od tada nastavilo eksponencijalno rasti, bez ikakvih prepreka u istraživanju te postalo integralni dio sistemske infrastrukture.

3.2. Neuronsko Računarstvo

Računala su u današnje vrijeme postala neizbježan dio naše svakodnevnice. Koriste se u obiteljskim domovima, državnim ustanovama, ugostiteljskim objektima i svugdje gdje je potrebna obrada podataka koja bi pospješila čovjekove radne performanse ili pružio oblik zabave. Iako takvi sistemi nisu dovoljno napredni da zadovolje sve zahtjeve i potrebe čovjeka, od njih se s vremenom očekivalo sve više. Kako bi se zadovoljio sve veći apetit za implementacijom računarskih sistema u svakodnevnoj infrastrukturi, pokrenula se inicijativa kako bi se takvi sistemi učinili "inteligentnijima", odnosno da funkcioniraju analogno ljudskom mozgu u rješavanju problema.

Ponašanje računalnog sistema smatra se inteligentnim ukoliko je sposobno donositi zaključke i odluke na temelju obrađenih informacija i činjenica. Operacije koje čovjek obavlja intuitivno poput prepoznavanja i klasificiranja uzoraka tepredviđanje ishoda na temelju prikupljenih informacija i iskustva iz svakodnevnog života, računalima su predstavljale nenadmašivu prepreku. Međutim, danas, nakon par desetljeća razvoja i poboljšanja svakog segmenta neuronskih mreža, susrećemo se s barem jednim oblikom takve inteligencije. Jedna od vjerojatno najkorištenijih je Google tražilica, koja koristeći sistem strojnog učenja (eng. *Machine Learning System*) ispravlja netočne upite za pretraživanje [2].



Slika 1–Prikaz ispravka rezultata na Google tražilici.

Izvor : Google (<https://www.google.hr/>)

3.3. Razlika biološke i umjetne neuronske mreže

Osnovna i najsloženija jedinica biološke neuronske mreže zove se neuron. Živčani sustav, kao biološka struktura za prijenos informacija, sastoji se od milijarda neurona gdje je svaki neuron povezan sa približno 10^4 drugih neurona. Neuron se sastoji od tijela stanice te dijelova odgovornih za primanje i slanje informacija zvanih dendriti i aksoni. Razmak koji dijeli završetak aksona prethodnog neurona i dendrita (tijela slijedećeg neurona) zove se sinapsa. Sinapsa služi da signali preko nje prelaze s jedne stanice na drugu električnim ili kemijskim putem.

Osnovna funkcija umjetnog neurona je da svojom građom i funkcijom oponašaju glavne funkcije biološkog neurona. Tako svojom strukturom vrlo nalikuju na biološki neuron. Kod umjetnog neurona tijelo stanice je zamijenjeno dijelom zvanim sumator, koji na temelju težinskih faktora sumira vrijednosti predane preko ulaznog sloja. Dendriti su predstavljeni kao ulazi u sumator, akson predstavlja izlaz iz njega dok aktivacijske funkcije preuzimaju ulogu praga osjetljivosti kod bioloških neurona.

Iako slične po arhitekturi i određenim funkcijama, umjetna neuronska mreža se uvelike razlikuje od biološke neuronske mreže, odnosno ljudskog mozga.

U tablici 1 su prezentirane njihove prednosti, nedostaci, mogućnosti i ograničenja [3].

Razlike	Biološka neuronska mreža	Umjetna neuronska mreža
Brzina	18ms – 150ms	Nekoliko nanosekunda
Veličina	10^{11} neurona	$10^2 - 10^4$ neurona
Podaci	Tolerantne na nepotpune podatke	Zahtijevaju potpune podatke
Jedinice za procesiranje	10^{14} sinapsa	10^8 tranzistora
Pohrana informacija	Pohranjuje se u sinapsama	Pohranjuje se u matricama
Kompleksnost	Vrlo kompleksna i detaljna	Manje kompleksna

Tabela 1- Razlike biološke i neuronske mreže

Izvor - Autor

4. IZRADA MODELA

Modeliranje sistema baziranog na neuro-fuzzy modelu u svrhu procjene zaposlivosti studenata sa Međimurskog veleučilišta temeljio se na prikupljenim sirovim podacima o tri studijska smjera. Sirovi podaci se sastoje od ukupno 417 uzoraka, od čega je 30 uzoraka bilo za smjer održivog razvoja, 120 za smjer računarstva te 287 za smjer menadžmenta.

Za izradu modela te njegovo treniranje i testiranje korišten je softverski paket MATLAB 2017a sa svojim *Data Analytics* i *Signal Processing and Communications* alatnim paketima. Bitno je za napomenuti kako efikasnost rada neuronske mreže ovisi o stanju i količini izvornih podataka te zbog toga mreže trenirane i testirane s većom količinom podataka garantiraju veću točnost i manji koeficijent greške.

Za potrebe ovoga rada testiranje i treniranje mreže obavljeno je na razini pojedinačnih smjerova i na razini veleučilišta na temelju sakupljenih podataka. Za kreiranje mreža opisanih u nastavku, korišten je alat *nntool* u sklopu Matlab-a.

Sve upotrebljene mreže u ovome radu koriste algoritam propagiranja greške unazad. On će omogućiti mijenjanje težine u smjeru najbržeg opadanja funkcije, odnosno negativni gradijent, što će u slučaju male količine podataka ostvariti najpovoljniji rezultat. Sve kreirane mreže sačinjavaju se od dva sloja, gdje je u prvom sloju implementirana tangentno-sigmoidna funkcija dok je u drugom samo linearna. Tri mreže koje obrađuju podatke na razini pojedinačnih smjerova sadrže pet neurona u skrivenom sloju, dok neuronska mreža na razini cijelog veleučilišta sadrži deset neurona.

Cilj je bio pronaći mreže s najmanjim intervalom učenja koji daje najbolji rezultat. Bilo je nužno obratiti posebnu pozornost na krivulje testiranja i validacije, promatrati njihove karakteristike te, ukoliko imaju slične karakteristike u epohama treniranja, odabrati točku najboljih karakteristika kao rezultat testiranja i treniranja mreže.

4.1. Pretprocesiranje podataka

Prikupljeni podaci u svojem sirovom stanju često su nepotpuni, atributi nemaju odgovarajuće vrijednosti ili potrebni atributi uopće ne postoje. Primjer takve strukture može se vidjeti na slici 2. Iz slike je vidljivo da podaci nisu sortirani, atributi i njihove vrijednosti nisu precizno definirane za potrebe ovoga rada nedostaje atribut za klasificiranje podataka.

Naziv elementa strukture	EVIDENCIJA NA ZAVOD	ZAPOSLENI	HZMO	INTERVENCIJE				
Programsko inženjerstvo	nikada nije bio u evidenciji	08.07.2013-	SSS	RO	informatičar/informatičarka			
Programsko inženjerstvo	31.10.2012 do	/						
Programsko inženjerstvo	07.12.2011-19.06.2012	20.6.2012-30.06.2016	SSS	RO	mehaničar/elektroničar/mehaničarka	€		
Programsko inženjerstvo	nikada nije bio u evidenciji	1.12.2007-15.10.2008.	NKV	RO	čistačica, prodavač/prodavačica			
Programsko inženjerstvo	nikada nije bio u evidenciji	16.9.2013-	VSS	SOR	diplomirani informatičar/diplomirana in			
Programsko inženjerstvo	odjava s evidencije, nezaposlen	17.2.2014-31.5.2014	SSS	RO	tehničar/tehničarka za programiranje			
Programsko inženjerstvo	nezaposlen, ali bez prijave	5.9.2012-30.6.2016	VŠS	SOR	elektroinženjer/elektroinženjerka			
Programsko inženjerstvo	nezaposlen, ali bez prijave	23.3.2015-22.03.2016	VŠS	SOR	inženjer/inženjerka sustava za računarstvo			
Programsko inženjerstvo	7.1.2014-30.6.2015.	1.7.2015-	VŠS	SOR	informatičar/informatičarka/tehničar/te			

Slika 2 - Primjer sirovih podataka
Izvor - Autor

U slučaju takve nekonzistentnosti i nepravilnosti izvornih podataka, čišćenje odnosno normalizacija je nužan korak prije učitavanja podataka u neuronsku mrežu. Metode normalizacije, koje se najčešće koriste u pretprocesiranju podataka, dijele se na tri kategorije [4].

- Min-max normiranje
- Z-skaliranje
- Decimalno skaliranje.

U svrhu ovoga rada odabrana je i izvršena normalizacija min-max metodom, koja se svodi na linearnu transformaciju podataka na novi raspon, najčešće od 0 do 1. Normalizacija min-max metodom se može i matematički prikazati formulom

$$y' = \frac{y - \min}{\max - \min} (\max' - \min') + \min'$$

gdje oznake korištene u formuli predstavljaju :

- \min' = nova normirana minimalna vrijednost
- \max' = nova normirana maksimalna vrijednost
- y' = nova normirana vrijednost atributa
- \min = minimalna vrijednost originalnog niza
- \max = maksimalna vrijednost originalnog niza
- y = izvorna vrijednost atributa

Nakon normalizacije izvornih podataka, dobiveno je pet ulaznih atributa i klasa za osnovnu obradu u modeliranju, odnosno treniranje i testiranje neuronske mreže (Slika 3). Svakom atributu dodijeljena je vrijednost u rasponu od 0 do 1, odnosno od 0% do 100%, dok klasa sadrži binarne vrijednosti [0-1].

EVIDENCIJA – označava evidenciju subjekta na zavodu za zapošljavanje

ZAPOSLENI – prikazuje status zaposlenosti

PRIJAVA – definira prijavu subjekta na zavodu za mirovinsko osiguranje na temelju stručne spreme

INTERVENCIJA – predstavlja vrstu intervencije poslodavca s ciljem zapošljavanja subjekta

RADNO MJESTO – prikazuje konačno radno mjesto subjekta

CLASS - klasa [0 ili 1]

	Evidencija	Zaposleni	Prijava HZMO	Intervencija	Radno Mjesto	Klasa
R1	0.35	1	0.3	1	1	1
R2	0.35	0	0	0	0	0
R3	0.35	0.75	0	1	0	1
R4	0	0.35	0	1	0	0
R5	0	1	1	1	1	1
R6	0	0.35	0.3	1	1	1
R7	0	0.35	1	1	0	1
R8	0	0.35	1	0.6	1	1
R9	0.35	1	0.3	1	1	1

Slika 3–Primjer pretprocesiranih podataka
Izvor – Autor

4.2. Podjela podataka

Nakon pretprocesiranja podataka, podaci se dijele na dva poduzorka. Jedan poduzorak će služiti za treniranje dok će se drugi koristiti za testiranje mreže. Ukoliko se prilikom učenja žele koristiti optimizacijske tehnike za kontrolu duljine učenja i strukturu mreže, potreban je još jedan poduzorak za konačnu validaciju. Omjer podjele prikupljenih podataka na manje poduzorke je proizvoljan iako se preporuča najveći poduzorak ostaviti za treniranje mreže. Za potrebe ovoga rada, omjer koji se pokazao najefikasnijim podijelio je pretprocesirane podatke na tri dijela. Od toga je 70% ukupnih podataka korišteno za treniranje mreže, 15% za testiranje, te 15% za validaciju.

4.3. Pravilo učenja

Neuronske mreže baziraju svoj princip rada na odabranom pravilu učenja koje podrazumijeva prikupljanje i pripremu potrebnih podataka. Sama faza učenja je proces podešavanja težinskih vrijednosti u mreži koja se odvija u više iteracija ili prolaza kroz mrežu. Postoje tri glavne paradigme učenja neuronskih mreža [7].

- Učenje pod nadzorom (eng. *Supervised Learning*)
- Učenje podrškom (eng. *Unsupervised Learning*)
- Učenje s nagradom (eng. *Reinforcement Learning*)

Za učenje neuronskih mreža u ovome radu odabrana je tehnika učenja s podrškom koja se temelji na prisustvu vanjskog učitelja i poznavanja željenih rezultata. Pogreška u ovome načinu učenja se računa kao razlika između željenog i dobivenog rezultata. Ukoliko je prag pogreške previsok i rezultati su nezadovoljavajući, parametri mreže se mijenjaju na temelju ulaznih podataka i razini pogreške sve dok mreža ne nauči imitirati učitelja.

Algoritam korišten za učenje pod nadzorom je algoritam s povratnom propagacijom pogreške.

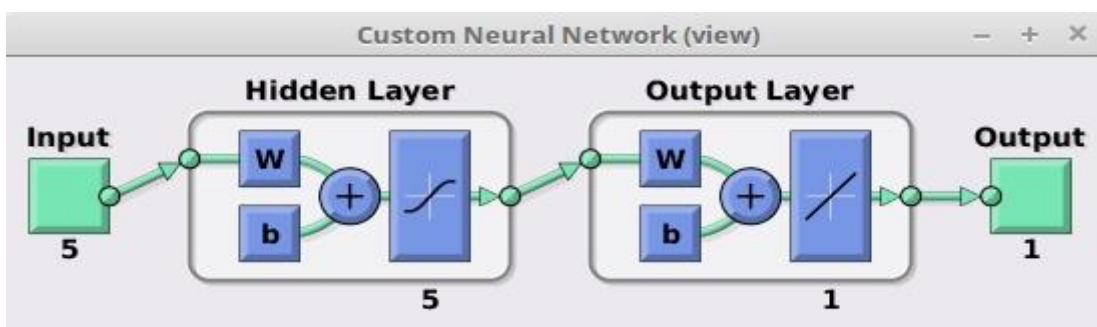
Nedostatak ovakvog načina učenja leži u nemogućnosti mreže da stekne novo znanje o okolini bez prisustva učitelja ukoliko novo stečeno znanje ovisi o primjerima koji nisu bili korišteni prilikom faze učenja mreže.

4.4. Arhitektura Mreža

Količina slojeva određuje arhitekturu mreže. Zato mreže po arhitekturi mogu biti jednoslojne i višeslojne. Mreže kreirane za potrebe ovoga rada su po arhitekturi dvoslojne te se sastoje od jednog skrivenog sloja i vanjskog sloja za prikaz rezultata.

4.4.1. Mreže za pojedinačne smjerove

Arhitektura tri zasebne mreže koje će raditi analize podataka na temelju određenih smjerova veleučilišta iste su po arhitekturi. Sadrže samo dva sloja, pet neurona i tangentno sigmoidnu funkciju u skrivenom sloju, te linearnu funkciju u izlaznom.

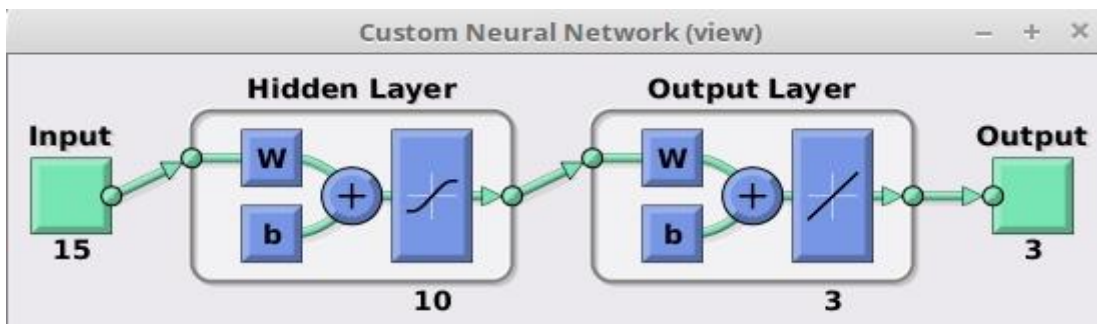


Slika 4 - Struktura mreža za pojedinačne smjerove

Izvor – Autor

4.4.2. Mreža za cijelo veleučilište

Kod kreirane mreže koja radi obradu podataka na temelju cijelog veleučilišta, pet neurona u skrivenom sloju nije davalo najefikasnije i dovoljno precizne rezultate. Zbog veće količine ulaznih atributa bilo je nužno i povećati količinu neurona u skrivenom sloju. Zato, za razliku od prethodne tri mreže, ova mreža sadrži deset neurona u skrivenom sloju, dok su funkcije prijenosa i aktivacije ostale iste.



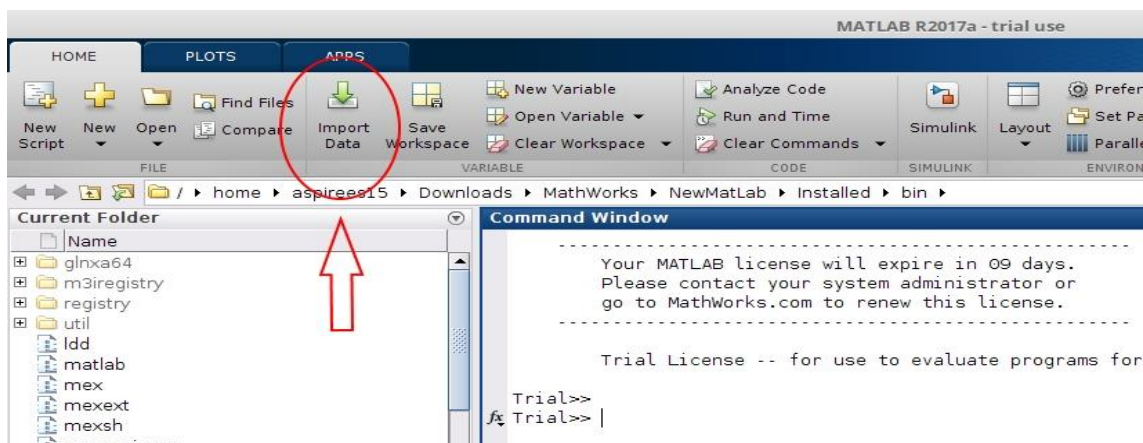
Slika 5 - Struktura mreže za cijelo veleučilište

Izvor - Autor

4.5. Kreiranje neuronskih mreža

Prije same izrade neuronske mreže, potrebno je učitati normalizirane podatke iz *Excel*-tablice u radni prostor (eng. *Workspace*) Matlab sučelja. Učitavanje podataka se može izvršiti na par načina, najjednostavniji je pomoću alatni izbornik i odvija se u tri koraka[8].

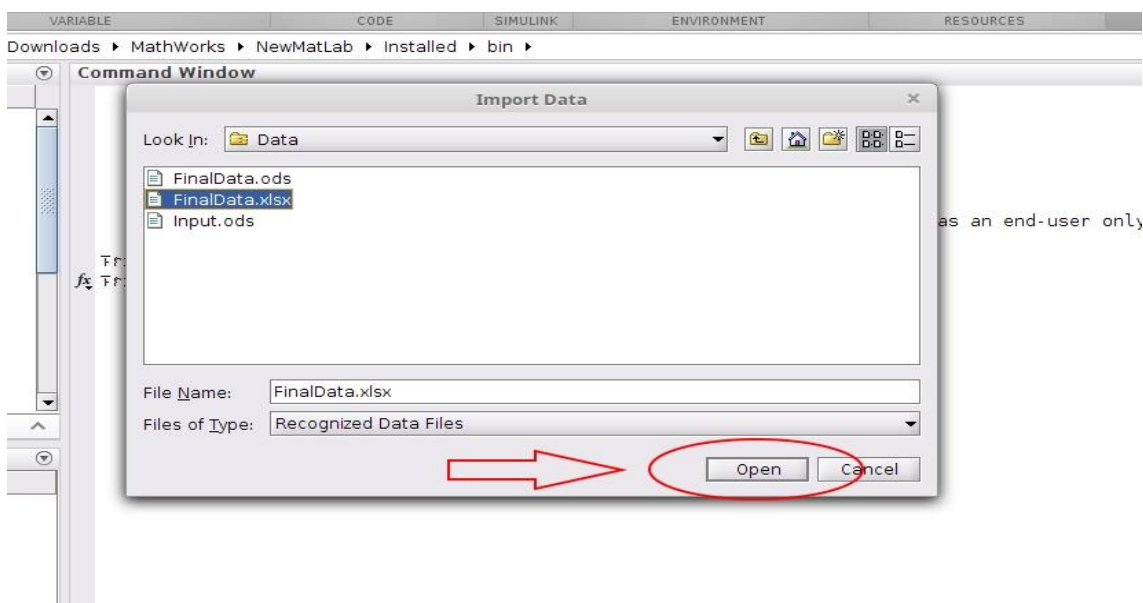
Na alatnom izborniku učitavanje podataka se izvršava pomoću klika na *Import Data*.



Slika 6 - Prikaz odabira podataka

Izvor : Autor

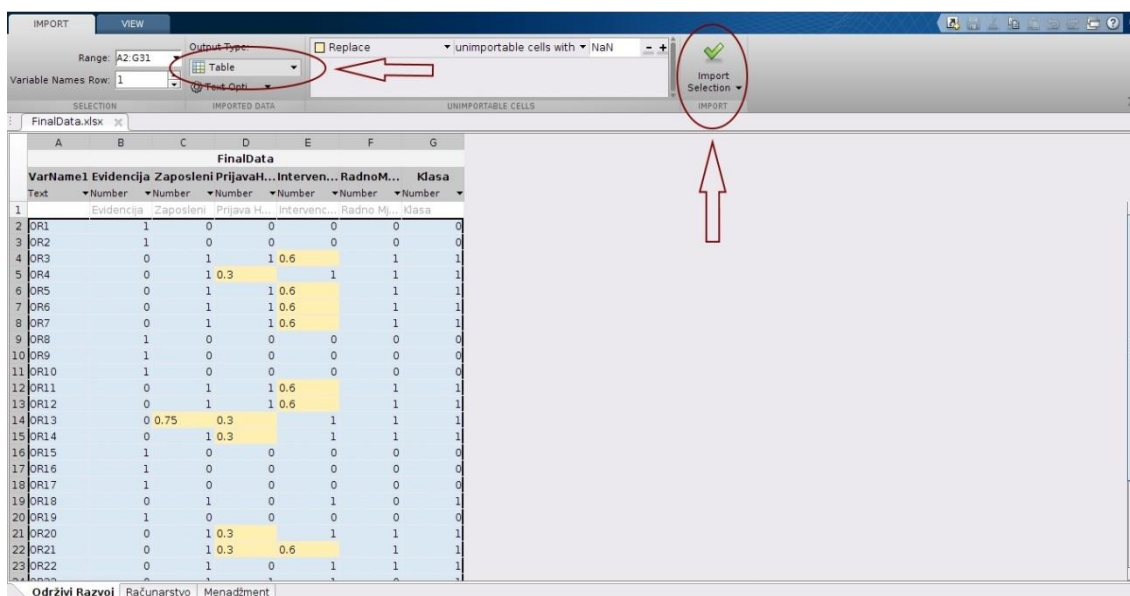
Slijedi navigacija do željene *Excel* tablice. Za učitavanje tablice potrebno je stisnuti *Open*.



Slika 7 - Prikaz odabira podataka

Izvor : Autor

Nakon odabira podataka, otvara se prozor u kojem je prikazan cijeli sadržaj odabrane *Excel* tablice. Ukoliko tablica sadrži više stranica podataka, oni će biti prikazani u donjem lijevom kutu. Prije samog učitavanja željenih podataka, potrebno je promijeniti *Output Type* iz podatkovnog tipa *Table* u *Numeric Matrix*. Nakon odabira željenog broja podataka i promjene podatkovnog tipa, potrebno je kliknuti na *Import Selection*.



Slika 8 - Prikaz učitavanja podataka

Izvor : Autor

Ukoliko su selekcija i učitavanje podataka prošli bez pogreške, učitana matrica s odabranim podacima se nalazi u *Workspace-u* i vidljiva je u donjem lijevom kutu Matlab sučelja (Slika 9.).



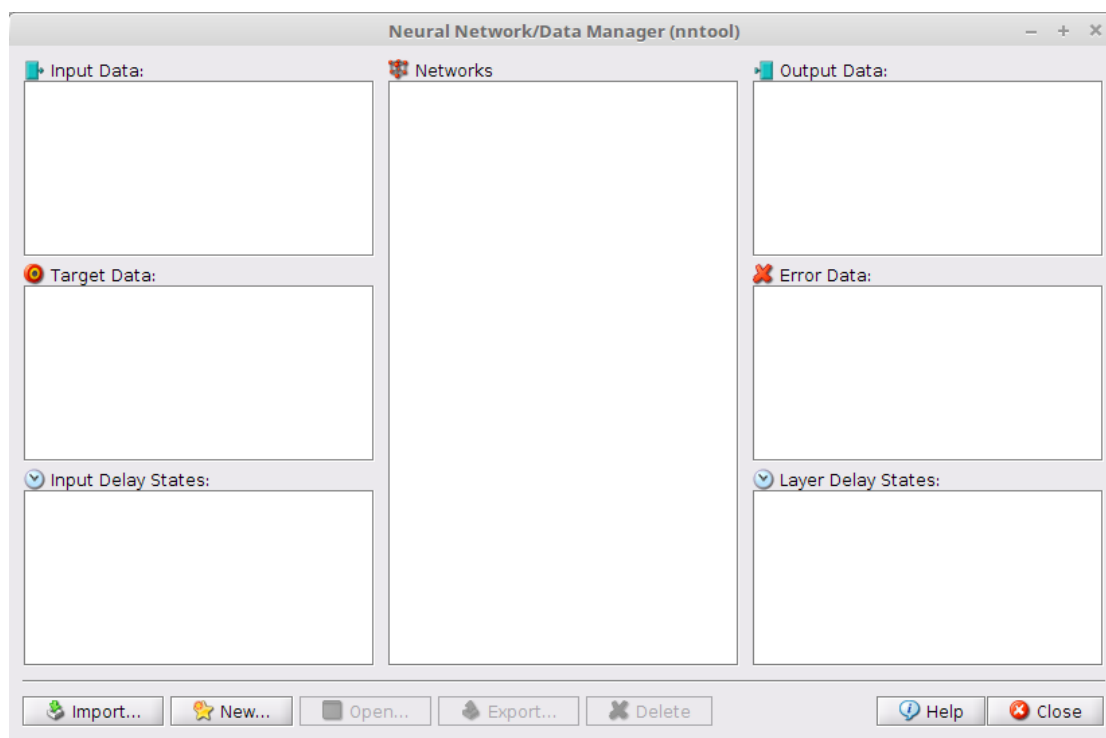
Slika 9 - Prikaz učitanih podataka

Autor - Izvor

4.5.1. Kreiranje neuronske mreže pomoću GUI-a

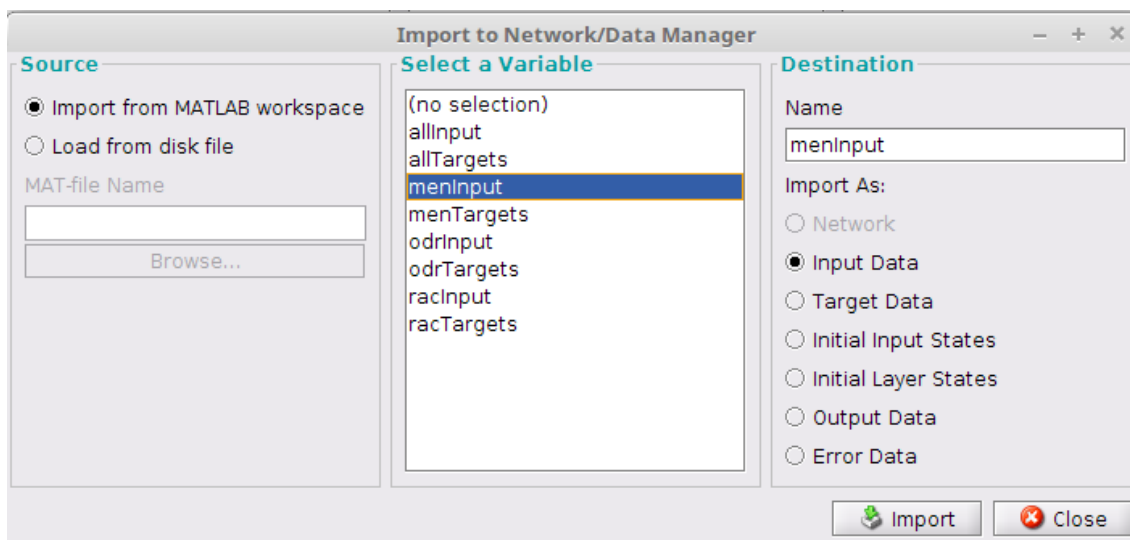
Ovdje će biti demonstrirano kreiranje neuronske mreže koja će procesirati podatke za smjer menadžmenta, prema prethodno predstavljenoj arhitekturi. Mreže za ostale smjerove, kao i mreža za cijelo veleučilište, prate ovakav princip rada. Bitno je napomenuti kako predstavljene performanse ne odražavaju odabrani rezultat ove mreže. Krajnji rezultat je dobiven nakon višestrukog testiranja mreže, ponovne inicijalizacije težinskih vrijednosti i mijenjanja broja neurona u skrivenom sloju. Međutim, prezentirani koraci bili su startne točke prema zadovoljavajućoj strukturi mreže i odgovarajućim rezultatima.

Nakon ispravnog učitavanja podataka i konverzije u matrice, kreiranje neuronske mreže će u ovome primjeru biti ostvareno pomoću alata *Neural Network/Data Manager*, pozivom naredbe *nntool* u komandnom prozoru MATLAB sučelja. Nakon unosa naredbe *nntool*, pojaviti će se iskočni prozor koji će poslužiti za određivanje ulaznih i izlaznih podataka, kreiranje mreže s odgovarajućim parametrima te na kraju njeno treniranje i testiranje.



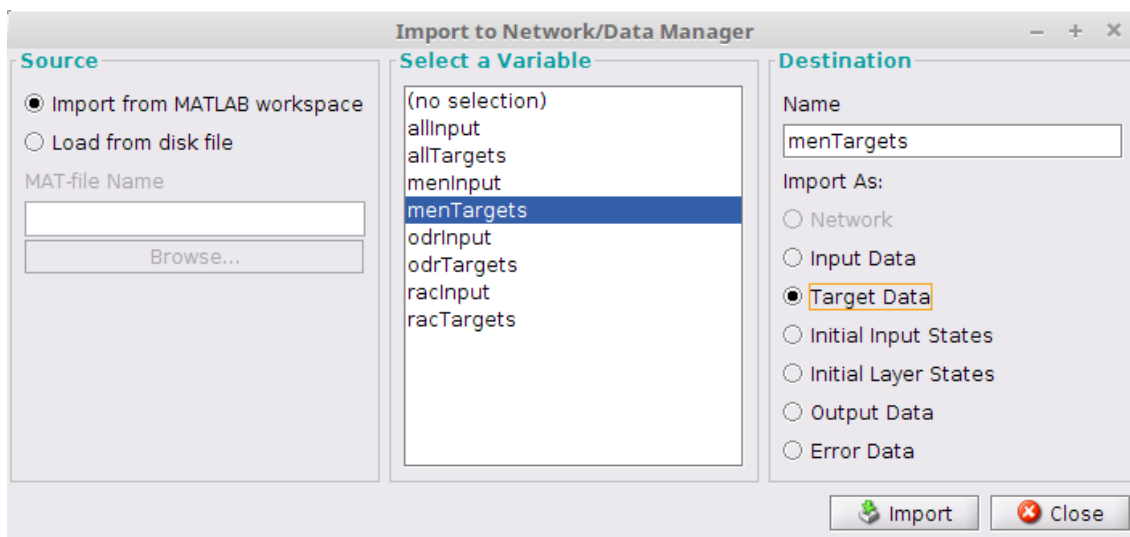
Slika 10–Neural Network/Data Manager
Izvor – Autor

Definiranje ulaznih i izlaznih podataka ostvaruje se opcijom *Import*, klikom na istoimeni gumb. Pritom se otvara dodatni prozor koji se dijeli na tri sekcije. Prva sekcija predstavlja izvor učitavanja podataka, po zadanim postavkama učitavanje će se izvršiti iz MATLAB radnog prostora. Svi podaci koji se nalaze u radnom prostoru bit će vidljivi u drugoj sekciji u kojoj je potrebno odabrati željene ulazne i izlazne podatke te ih upariti sa odgovarajućom destinacijom učitavanja u trećoj sekciji.



Slika 11 - Odabir ulaznih podataka

Izvor – Autor

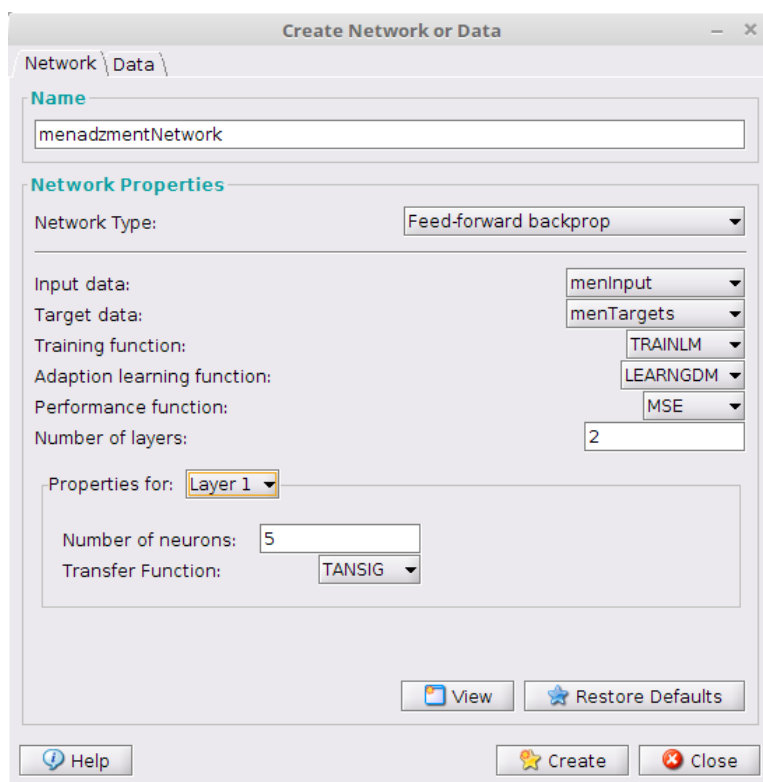


Slika 12 - Odabir izlaznih podataka

Izvor – Autor

Nakon određivanja ulaznih i izlaznih podataka, pritiskom na gumb *New* (slika 10.) otvara se alat za kreiranje neuronske mreže (Slika 13.). Prije samog kreiranja, bitno je definirati određene karakteristike mreže. Tip mreže koji se kreira je *feed-forward backprop*, što znači da je ova mreža samo unaprijedna sa algoritmom povratnogpropagiranja pogreške. Funkcija koja se koristi za treniranje je Levenberg-Marquardt (TRAINLM), dok je funkcija adaptivnog učenja gradijentnog spusta. Sadrži dva sloja, gdje prvi sloj ima pet neurona i tangentno sigmoidnu funkciju, dok drugi sloj ima linearnu funkciju prijenosa.

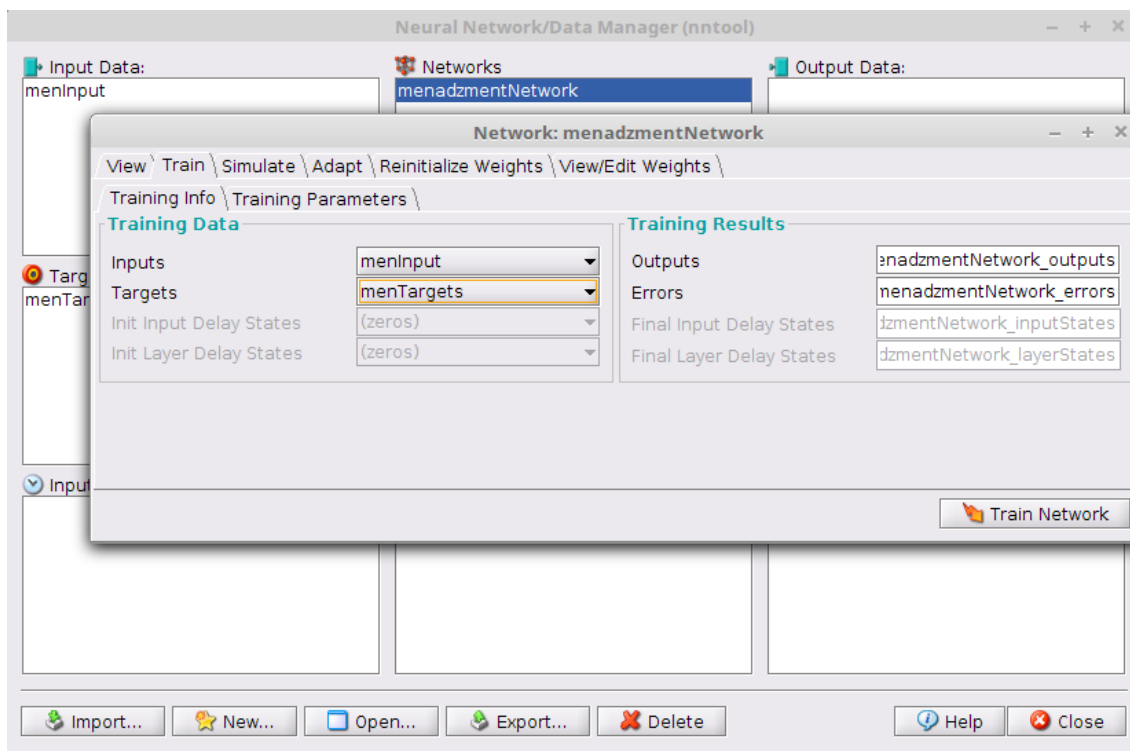
Ukoliko se želi provjeriti struktura mreže na temelju definiranih atributa, to je ostvarivo pomoću gumba *View*. Ako uneseni podaci odgovaraju zahtjevima mreže, pritiskom na gumb *Create*, definirana mreža će biti stvorena i vidljiva na drugoj sekciji *Neural Network/Data Manager-a* (Slika 10.).



Slika 13 - Prikaz kreiranja mreže

Izvor – Autor

Pritiskom na kreiranu mrežu omogućiti će se funkcionalnosti poput otvaranja, eksportiranja i brisanja odabrane mreže. Klikom na gumb *Open*, možemo otvoriti mrežu. Otvaranje mreže će ponuditi dodatne opcije potrebne za treniranje i testiranje mreže, poput podešavanja podataka, namještanja parametara za učenje, simuliranja mreže te inicijalizacije težinskih vrijednosti. Za treniranje mreže potrebno je navigirati do kartice *Train* te nakon učitavanja ulaznih i izlaznih podataka, pritisnuti gumb *Train Network*.

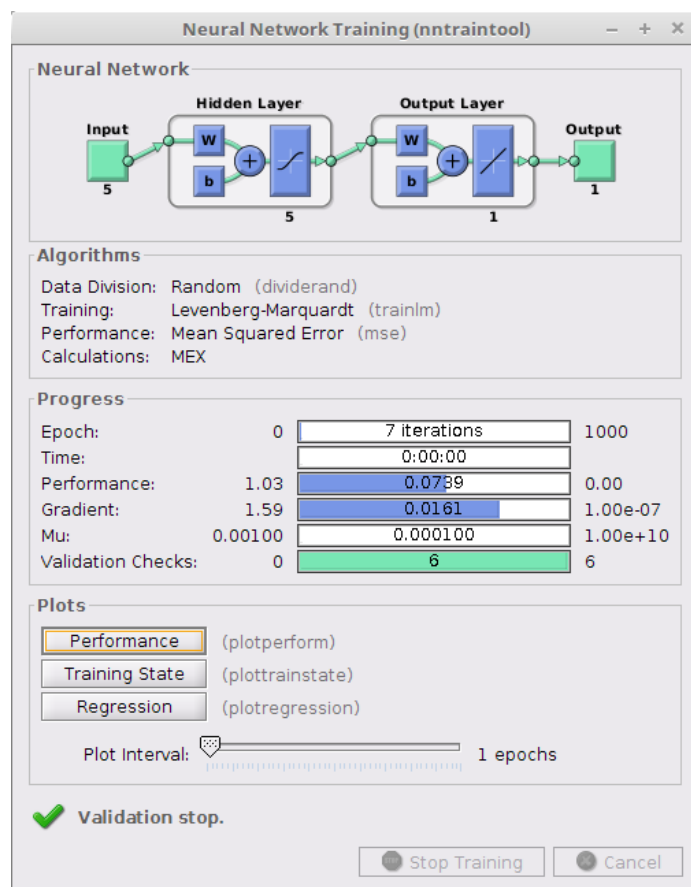


Slika 14 - Prikaz treniranja mreže

Izvor – Autor

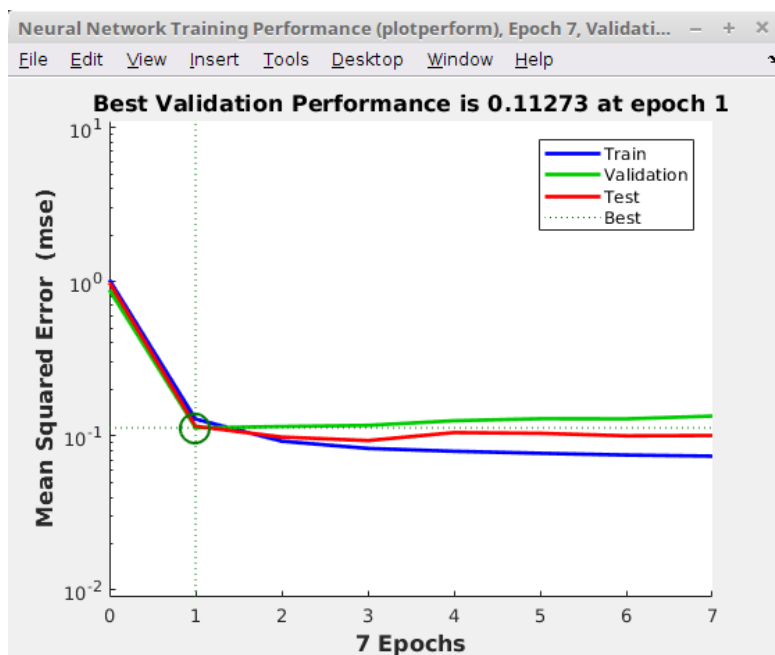
Prilikom treniranja mreže prikazati će se prozor sa rezultatima, na kojemu je moguće vidjeti strukturu mreže, korištene funkcije, broj epoha, vrijeme treniranja, performans, vrijednost gradijentnog spusta te broj validacijskih provjera.

Ključni segmenti provjere rada mreže, nalaze se pod sekcijom *Plots*. Ondje je moguće, pritiskom na gumb *Performance*, provjeriti performans mreže pomoću dijagrama treniranja koji krivuljama predstavlja promjenu vrijednosti faze treniranja, testiranja i validacije epoha.



Slika 15 - Rezultati mreže

Izvor – Autor




Slika 16 - Performanse mreže

Izvor – Autor

Na slici 16. vidljivo je kako je najbolji performans mreže, baziran na definiranim ulaznim i izlaznim podacima, nastupio u prvoj epohi i iznosi 0.11273. Prilikom određivanja krajnjeg i zadovoljavajućeg rezultata mreže, bitno je uzeti u obzir određene karakteristike mreže. Kao prvo, krajnji rezultat mreže morao bi biti najmanji mogući, pri kojem krivulje za testiranje i validaciju imaju najviše zajedničkih točaka. Kao drugo, preporuča se odabrati rezultat koji je nastupio nakon određenog broja epoha, s čime se garantira preciznija analiza [9.].

U ovome slučaju, iako je vrijednost pogreške mala, najbolji performans je nastupio prilikom prve epohe. Pošto je preporučljivo da krajnji rezultat nastupi nakon određenog broja epoha, poželjno je ponovo trenirati mrežu i promatrati rezultate. Kako bi se izbjeglo pretreniranje mreže i dobivanje netočnih rezultata, navigacijom do kartice *Reinitialize Weights* (Slika 14.) moguće je postaviti težine na prijašnju vrijednost ili inicijalizirati na novu.

Ponovna inicijalizacija težina na novu vrijednost, rezultirala je performansom mreže vidljivim na slici 17. Vidljivo je kako je vrijednost pogreške manja nego pri prošlom treniranju, najbolje performanse su nastupile prilikom treće epohe, te do toga trena su krivulje za testiranje i validaciju imale najviše zajedničkih karakteristika.



Slika 17 - Prikaz novih performansi

Izvor - Autor

4.5.1. Kreiranje neuronske mreže pomoću programskog koda

Iako kreiranje neuronske mreže pomoću grafičkog sučelja nosi određene prednosti, programiranje mreže pomoću komandnog prozora daje bolji uvid u funkcioniranje zasebnih segmenata. Ovo poglavlje će kroz par koraka demonstrirati izradu neuronske mreže, njeno treniranje i testiranje te usporediti rezultate s onima dobivenim pomoću grafičkog sučelja. Za ulazne i ciljane podatke, koristit će se isti kao u primjeru sa grafičkim sučeljem, odnosno `menInput` i `menTargets` te će mreža koristiti iste aktivacijske funkcije sa jednakim brojem neurona u skrivenom sloju.

Za korištenje podataka pomoću programskog koda, podaci se mogu učitati na isti način kao i kod izrade neuronske mreže preko GUI-a, krajnje je potrebno da se oni nalaze u radnom prostoru (eng. *Workspace*) Matlab sučelja.

1. Za definiranje ulaznih i ciljanih podataka potrebno je kreirati dvije varijable te njihove vrijednosti inicijalizirati na numeričke matrice koje predstavljaju te podatke u radnom prostoru.

```
inputs = menInputs;  
  
targets = menTargets;
```

2. Kreiranje mreže započinje određivanjem broja neurona u njenom skrivenom sloju. Iako je moguće raditi detaljnije i opširnije određivanje mreže, ovo je jedan od bržih i efikasnijih načina. Kao i u slučaju kreiranja mreže preko GUI-a, ovdje ćemo također dodijeliti pet neurona skrivenom sloju. Zadana mreža za prepoznavanje uzoraka i regresijske probleme je *feedforward* mreža s tangentno-sigmoidnom prijenosnom funkcijom u skrivenom sloju i linearnom funkcijom u izlaznom, koja se poziva pomoću naredbe *fitnet*.

```
hiddenLayerSize = 5;  
  
net = fitnet(hiddenLayerSize);
```


3. Nakon definiranje broja neurona u skrivenom sloju, trebala bi u radnom prostoru biti vidljiva varijabla koja označava kreiranu mrežu s određenim brojem neurona. Dalje je potrebno definirati omjere poduzoraka za treniranje, testiranje i validaciju. Kao i u slučaju s grafičkim sučeljem, ovdje ćemo također dodijeliti 70% ukupnih podataka za treniranje, 15% za validaciju, te 15% za testiranje mreže.


```
net.divideParam.trainRatio = 70/100;  
net.divideParam.valRatio = 15/100;  
net.divideParam.testRatio = 15/100;
```

4. Nakon definiranja omjera poduzoraka, mrežu je potrebno testirati. Kao i u Neural Network/Data Manageru (Slika 13.), zadana funkcija za treniranje koristi Levenberg-Marquardt (trainlm) algoritam. Ukoliko on ne zadovoljava potrebe kreirane mreže zbog nedovoljne preciznosti na velikom broju uzoraka, moguće ju je promijeniti u Bayesian Regularization (1) ili Scaled Conjugate Gradient algoritam (2). Za potrebe ove mreže ta funkcija odgovara, te ćemo ju trenirati bez mijenjanja algoritma (3).

```
net.trainFcn = 'trainbr'; (1)  
  
net.trainFcn = 'trainscg'; (2)  
  
[net, tr] = train(net, inputs, targets); (3)
```

Tijekom treniranja ponovo će se prikazati prozor sa rezultatima (Slika 15.) na kojem je moguće prekinuti treniranje mreže koje u progresu ili vidjeti performanse, regresiju, broj epoha i provjeru validacije. Programskim kodom se također može provjeriti odskaku li performanse, broj pogrešaka ili izlazu onima dobivenim na prozoru sa rezultatima.

```
outputs = net(inputs);  
  
errors = gsubtract(targets, outputs);  
  
performance = perform(net, targets, outputs)  
  
performance = 0.10361
```

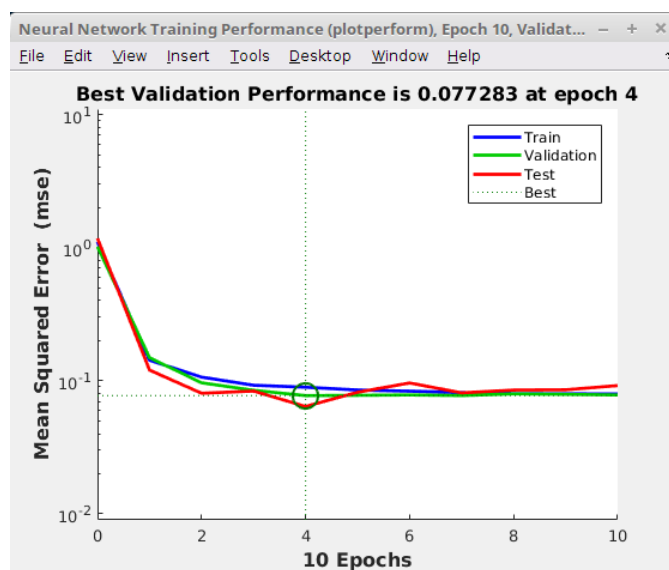


Slika 18 - Prikaz performansi

Izvor – Autor

Vidljivo je da je najbolji performans približno jednak onome dobivenome pomoću grafičkog sučelja, manje odstupanje i razlike u vrijednosti su normalne radi različitih težišnih vrijednosti generirane za slojeve mreže. Ponovna inicijalizacija težina moguća je pomoću naredbe *revert* (4), koja daje rezultate prikazane na slici 19. Vidljivo je kako je ovaj put najbolji performans nastupio prilikom četvrte epohe razlikom u grešci od 0.000175 u usporedbi sa najboljim performansom dobivenim preko GUI-a.

```
net = revert(net); (4)
```



Slika 19 - Prikaz novih performansi

Izvor - Autor

4.6. Rezultati

Nad svakom mrežom obavljena su višestruka testiranja koja su se sastojala od mijenjanja broja neurona, promjene prijenosne i aktivacijske funkcije te različitom podjelom poduzoraka za treniranje, testiranje i validaciju. Kod mreža baziranim na pojedinačnim smjerovima, najefikasnija struktura sastojala se od pet neurona u skrivenom sloju, dok je kod mreže na bazi veleučilišta deset neurona u skrivenom sloju pokazalo najbolje rezultate. Sve mreže koriste tangentno-sigmoidnu funkciju u skrivenom sloju te linearnu u izlaznom. Kod korištene količine podataka, podjela uzoraka na 70% za treniranje, 15% za testiranje i 15 % za validaciju se pokazala idealnom.

Od svake mreže izdvojeno je deset zadovoljavajućih rezultata te je naposljetku iz svakog skupa odabran krajnji rezultat koji najtočnije prikazuje funkcionalnost određene mreže. Odabrani krajnji rezultati zadovoljavaju sve kriterije treniranja mreže. U svojim zasebnim skupovima su najmanje vrijednosti prilikom kojih krivulje testa i validacije imaju najviše zajedničkih karakteristika te su nastupili nakon određenog broja epoha.

4.6.1. Neuronska mreža za smjer računarstva


U tabeli 2. vidljivo je deset mreža sa različitim rezultatima, od kojih se rezultat mreže N10 uzeo kao krajnji.

Ime	Broj neurona	Funkcija u skrivenom sloju	Funkcija u izlaznom sloju	Broj epoha	Epoha najboljeg performansa	Najniža greška
R1	5	Tansig	purelin	10	4	0.039285
R2	5	Tansig	Purelin	13	7	0.094425
R3	5	Tansig	Purelin	14	8	0.14281
R4	5	Tansig	Purelin	17	11	0.040661
R5	5	Tansig	Purelin	9	3	0.1622
R6	5	Tansig	Purelin	11	5	0.15767
R7	5	Tansig	Purelin	8	2	0.081417
R8	5	Tansig	Purelin	10	4	0.082104
R9	5	Tansig	Purelin	9	3	0.13672
R10	5	tansig	Purelin	8	2	0.077482

Tabela 2 - Rezultati neuronske mreže za smjer računarstvo

Izvor- Autor

S obzirom da suprilikom druge epohe krivulje za testiranje i validaciju imale najviše zajedničkih karakteristika, za razliku od mreža s manjom vrijednošću greške, ovaj rezultat se je pokazao idealnim za količinu podataka kojima se mreža trenirala.



Slika 20 - Prikaz najboljeg rezultata

Izvor – Autor

4.6.2. Neuronska mreža za smjer menadžmenta

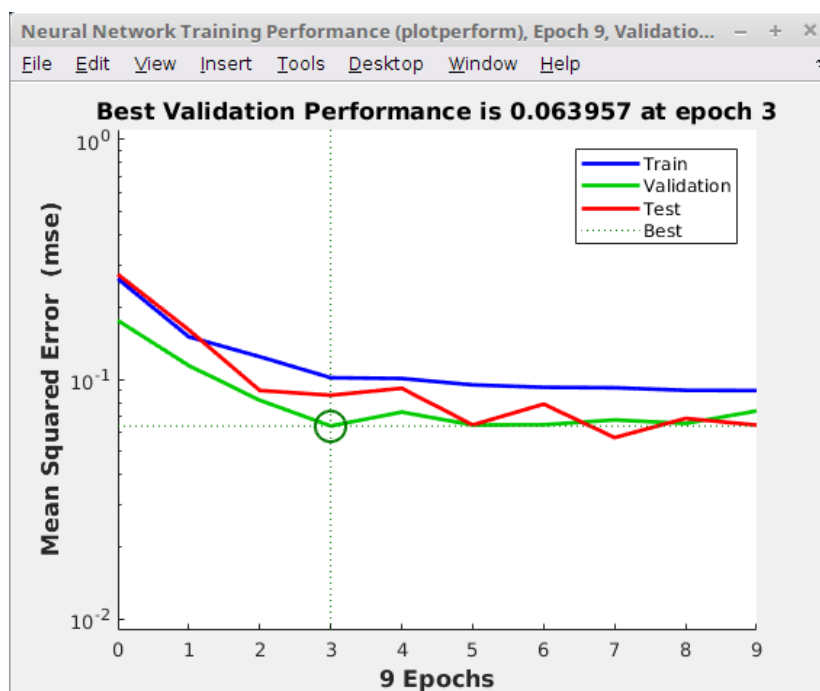
Mreža za smjer *menadžment* koristila je drugu najveću količinu podataka, ukupno 287 uzoraka. Od toga, 187 za treniranje, 40 za validaciju i 40 za testiranje. Pošto je njen broj uzoraka veći, rezultat su bili precizniji i odstupanja između njih su bila manja. Zato je bilo nužno posebnu pozornost obratiti na krivulje validacije i testiranje te mjesto nastajanja najmanje pogreške.

Od odabranih deset potencijalno zadovoljavajućih rezultata (Tabela 3.), mreža pod imenom M4 se pokazala idealnom, sa svega 9 epoha i greškom od 0.63957. Dijagramski prikaz krajnjeg rezultata vidljiv je na slici 21.

Ime	Broj neurona	Funkcija u skrivenom sloju	Funkcija u izlaznom sloju	Broj epoha	Epoha najboljeg performansa	Najniža greška
M1	5	Tansig	purelin	8	2	0.047687
M2	5	Tansig	Purelin	16	10	0.069797
M3	5	Tansig	Purelin	19	13	0.042453
M4	5	Tansig	Purelin	9	3	0.063957
M5	5	Tansig	Purelin	12	6	0.08165
M6	5	Tansig	Purelin	10	4	0.11554
M7	5	Tansig	Purelin	11	5	0.074923
M8	5	Tansig	Purelin	19	13	0.097537
M9	5	Tansig	Purelin	9	3	0.077458
M10	5	tansig	Purelin	10	4	0.18177

Tabela 3 - Rezultati neuronske mreže za smjer menadžmenta

Izvor – Autor



Slika 21 - Prikaz najboljeg rezultata

Izvor – Autor

Najmanja greška i najbolji performans nastupio je prilikom treće epohe. Iako je mreža ostvarila vrijednosti manje od odabranog rezultata, krivulje za test i validaciju nisu imale zadovoljavajuće karakteristike te zbog toga nisu bile dovoljno funkcionalne.

4.6.3. Neuronska mreža za smjer održivog razvoja


Sa svega samo 30 uzoraka za testiranje, treniranje i validaciju mreže, neuronska mreža za smjer održivog razvoja je koristila najmanju količinu prikupljenih podataka. Međutim, zahtijevala je najviše testiranja zbog nekonzistentnih rezultata.

Od deset izdvojenih mreža, idealna krivulja po karakteristikama i najnižoj grešci pokazala se mreža O8.

Ime	Broj neurona	Funkcija u skrivenom sloju	Funkcija u izlaznom sloju	Broj epoha	Epoha najboljeg performansa	Najniža greška
O1	5	Tansig	purelin	31	31	$1.124 \cdot 10^{-7}$
O2	5	Tansig	Purelin	7	1	0.09932
O3	5	Tansig	Purelin	9	4	0.031279
O4	5	Tansig	Purelin	8	7	$1.724 \cdot 10^{-6}$
O5	5	Tansig	Purelin	25	25	$1.088 \cdot 10^{-7}$
O6	5	Tansig	Purelin	19	19	0.000353
O7	5	Tansig	Purelin	27	27	$8.657 \cdot 10^{-8}$
O8	5	Tansig	Purelin	25	25	$8.405 \cdot 10^{-8}$
O9	5	Tansig	Purelin	8	2	0.56529
O10	5	tansig	Purelin	10	4	0.15861

Tabela 4 - Rezultati neuronskih mreža za smjer održivog razvoja

Izvor – Autor



Slika 22 - Prikaz najboljeg performansa

Izvor – Autor


4.6.4. Neuronska mreža na razini veleučilišta

Za treniranje mreže na razini veleučilišta, korištena je najveća količina podataka. Matrica veličine 15*287 korištena je za ulazne podatke što je rezultiralo preciznijim izlaznim podacima. To je vidljivo u tabeli 5 pod stupcem najmanje greške gdje je razlika između rezultata najmanja u usporedbi sa prethodne tri mreže. Zadovoljavajući rezultat pokazala je mreža V8, sa greškom od 0.046794 u četvrtoj epohi.

Ime	Broj neurona	Funkcija u skrivenom sloju	Funkcija u izlaznom sloju	Broj epoha	Epoha najboljeg performansa	Najniža greška
V1	10	Tansig	purelin	11	5	0.055817
V2	10	Tansig	Purelin	10	4	0.064241
V3	10	Tansig	Purelin	10	4	0.080498
V4	10	Tansig	Purelin	14	8	0.068542
V5	10	Tansig	Purelin	8	2	0.057691
V6	10	Tansig	Purelin	10	4	0.065313
V7	10	Tansig	Purelin	10	4	0.078926
V8	10	Tansig	Purelin	10	4	0.046794
V9	10	Tansig	Purelin	12	6	0.062336
V10	10	tansig	Purelin	11	5	0.07075

Tabela 5 - Rezultati mreže na razini veleučilišta

Izvor – Autor



Slika 23 - Prikaz najboljeg performansa

Izvor - Autor

5. ZAKLJUČAK

Smanjenje nezaposlenosti trenutačno je jedan od najvažnijih prioriteta. Povezanost između dugotrajne nezaposlenosti i niske razine obrazovanja je očigledna. Međutim, problemi na koje nailaze mnogi dugotrajno nezaposleni građani su višedimenzionalni te često uključuju i manjak motivacije za daljnjim obrazovanjem. Akademsko obrazovanje se često smatraju neisplativima zbog financijskih ulaganja ili čak nedostatka garancije zaposlivosti. Zatobi sustavi bazirani na analizi procjene zaposlivosti, nakon završavanja akademskog obrazovanja, postali ključni segment poticaja dugotrajno nezaposlenih osoba. U ovome radu istražena je mogućnost procjene zaposlivosti nakon završavanja Međimurskog veleučilišta u Čakovcu na temelju prikupljenih podataka sa zavoda za zapošljavanje.

Cilj rada bio je razviti model inteligentnog sustavakoji bi pomoću tehnologije neuronskih mreža vršio analizu i procjenu zaposlivosti na temelju specifičnih ulaznih parametara. U ovome radu korišten je iznimno mali broj ulaznih atributa što je bio rezultat nepotpunih izvornih podataka. Pošto bolja funkcionalnost neuronskih mreža ovisi upravo o količini ulaznih podataka, bitno je za napomenuti kako se manja količina atributa pokazala kao ograničavajući faktor u izradi ovoga modela te ujedno predstavlja glavni nedostatak u ovome radu.

Iako rezultati modela nisu potpuno zadovoljavajući, pružaju potencijalno dobru startnu točku za daljnje istraživanje i razvijanje ovakvih sustava. Prezentirane tehnike pokazale su se dovoljno sposobne za rješavanje ovakve vrste analitičkih problema. Veća količina podataka rezultirala bi preciznijom analizom te samim time bi modeli postali pouzdani izvori procjene zaposlivosti.

6. LITERATURA

- [1] History of neural network.
<https://cs.stanford.edu/people/eroberts/courses/soco/projects/neural-networks/History/history1.html> (15.05.2017.)
- [2] Metz C. – AI is changing the technology behind google searches,
<https://www.wired.com/2016/02/ai-is-changing-the-technology-behind-google-searches/> (07.06.2017)
- [3] O.S. Eluyode ; Akomolafe D. T. (2013) Comparative study of biological and artificial networks. Ondo State, Nigeria. European Journal of Applied Engineering and Scientific Research.
- [4] Knok Ž. (2014). Model hijerarhijske strukture neuro-fuzzy sistema i dizajn interfejsa za procjenu rizika od šećerne bolesti, Sarajevo.
- [5] Novaković, B. (1998). Umjetne neuronske mreže. Zagreb: Fakultet strojarstva i brodogradnje.
- [6] Sincero S. M. Types of neurons
<https://explorable.com/types-of-neurons> (01.07.2017.)
- [7] Eris Foi. Neuronske mreže, <http://eris.foi.hr/11neuronske/nn-predavanje4.html> (12.08.2017.)
- [8] Beale M. H. ; Hagan M. T. ; Demuth H. B. Neural Network Toolbox Guide
https://www.mathworks.com/help/pdf_doc/nnet/nnet_ug.pdf (18.08.2017.)
- [9] B. Dalbelo Bašić, M. Čupić, J. Šnajder (2008) Umjetne neuronske mreže. Fakultet elektrotehnike i računarstva.
- [10] Britz D. Recurrent Neural Networks Tutorial, Part 1 – Introduction to RNNs
<http://www.wildml.com/2015/09/recurrent-neural-networks-tutorial-part-1-introduction-to-rnns/> (20.08.2017.)

7. PRILOG A : PODACI

7.1. Prilog A-1

U ovome prilogu nalaze se normalizirani podaci za smjer održivog razvoja.

	Evidencija	Zaposleni	Prijava HZMO	Intervencija	Radno Mjesto	Klasa
OR1	1	0	0	0	0	0
OR2	1	0	0	0	0	0
OR3	0	1	1	0.6	1	1
OR4	0	1	0.3	1	1	1
OR5	0	1	1	0.6	1	1
OR6	0	1	1	0.6	1	1
OR7	0	1	1	0.6	1	1
OR8	1	0	0	0	0	0
OR9	1	0	0	0	0	0
OR10	1	0	0	0	0	0
OR11	0	1	1	0.6	1	1
OR12	0	1	1	0.6	1	1
OR13	0	0.75	0.3	1	1	1
OR14	0	1	0.3	1	1	1
OR15	1	0	0	0	0	0
OR16	1	0	0	0	0	0
OR17	1	0	0	0	0	0
OR18	0	1	0	1	0	1
OR19	1	0	0	0	0	0
OR20	0	1	0.3	1	1	1
OR21	0	1	0.3	0.6	1	1
OR22	0	1	0	1	1	1
OR23	0	1	1	1	0	1
OR24	0	0.75	1	1	1	1
OR25	0	0.5	0	1	0	0
OR26	0	0.5	0.3	0	1	0
OR27	1	0	0	0	0	0
OR28	0	1	1	0.6	1	1
OR29	0	1	0.3	1	1	1
OR30	1	0.5	0	1	0	0

7.2. Prilog A-2

U ovome prilogu nalaze se normalizirani podaci za smjer računarstva.

	Evidencija	Zaposleni	Prijava HZMO	Intervencija	Radno Mjesto	Klasa
R1	0	1	0.3	1	1	1
R2	0.35	0	0	0	0	0
R3	0.35	0.75	0	1	0	1
R4	0	0.35	0	1	0	0
R5	0	1	1	1	1	1
R6	0	0.35	0.3	1	1	1
R7	0	0.35	1	1	0	1
R8	0	0.35	1	0.6	1	1
R9	0.35	1	0.3	1	1	1
R10	0.75	1	0.3	0	1	1
R11	0.75	1	0.3		1	1
R12	0.75	0.75	0.3	1	1	1
R13	0.35	1	1	0.6	1	1
R16	0.75	1	0.3	1	1	1
R17	0.75	1	0.3	1	0	1
R19	0.75	0.35	1	0.6	1	1
R20	0.35	1	1	0.6	1	1
R21	0.35	1	1	1	1	1
R22	0	0.35	0.3	1	0	0
R23	0.35	1	1	0.6	1	1
R24	0.75	1	1	1	1	1
R25	0.75	0.35	1	0.6	1	1
R26	0.35	1	1	1	1	1
R27	0.35	0.35	1	0.6	1	1
R28	0	0.35	1	0.6	1	0
R29	0	1	1	1	0	0
R30	0.35	1	1	1	0	0
R34	0.35	1	1	0.6	1	1
R36	0.35	1	1	1	1	1
R37	0	1	0.3	1	1	1
R38	0.35	1	1	1	1	1
R39	0.75	0.35	1	1	1	1
R40	0.35	1	1	1	1	1
R41	0.35	1	1	0	0	0
R42	0.35	1	1	1	1	1
R43	0.35	1	1	1	1	1
R44	0.35	1	1	1	1	1

R45	0.35	1	1	1	1	1
R46	0.35	1	0.3	1	1	1
R47	0.35	1	1	1	1	1
R48	0.75	0.35	1	1	1	1
R49	0.35	1	0.3	1	0	0
R50	0.75	0.35	1	1	1	1
R51	0.35	1	1	1	1	1
R52	0.35	1	1	1	1	1
R53	1	1	0	1	0	0
R54	0	0.35	0.3	1	1	0
R55	0.35	1	1	1	0	0
R56	0	1	1	1	0	0
R57	0.35	1	0.3	1	0	0
R58	0.35	1	1	1	1	1
R59	0.35	1	1	1	1	1
R60	0.35	1	1	1	1	1
R61	0.35	1	1	0.6	1	0
R62	0.35	1	1	0.6	1	1
R63	0.35	0.75	1	1	1	1
R64	0.35	1	1	1	1	1
R66	0.75	0.35	1	0.6	1	1
R68	0.75	0.35	1	0.6	0	0
R69	0.35	1	1	1	1	1
R70	0.35	1	1	1	1	1
R71	0.35	1	1	0.6	1	1
R72	0.75	0.35	1	0.6	1	1
R73	0.35	1	1	0.6	1	1
R74	0.35	1	1	1	1	1
R75	0.35	1	0.3	1	1	1
R76	0.75	1	1	0.6	0	0
R79	0.35	1	1	1	1	1
R80	0	1	0	1	0	0
R81	0.35	1	0.3	1	0	0
R82	0.35	1	1	1	1	1
R83	0.35	1	1	0.6	1	1
R84	0	1	1	1	1	1
R87	0.35	1	0.3	1	0	0
R88	0.35	1	1	0.6	1	1
R89	0.35	1	1	0.6	0	1
R91	0.35	1	1	0.6	1	1
R92	0.35	1	1	1	1	1
R93	0.75	1	1	1	1	1
R94	0.75	1	1	1	1	1

R95	0.75	1	0.3	1	1	1
R96	1	1	0.3	1	1	1
R97	1	1	1	1	1	1
R98	0.75	1	1	1	0	1
R99	0.75	1	1	1	1	1
R100	0	0.35	1	0.6	1	1
R102	0	1	0	1	0	0
R103	0.75	1	0.3	1	1	1
R104	0.75	1	1	1	1	1
R105	0.75	1	0.3	1	0	0
R106	0.35	1	0.3	1	1	1
R107	0.75	1	0.3	1	0	1
R108	1	1	0	1	0	0
R109	0.35	1	0.3	1	0	0
R110	0.35	1	1	1	1	1
R111	0.75	0.35	0.3	1	1	1
R112	0.75	1	1	1	1	1
R113	0.35	1	0.3	1	1	1
R115	0.75	1	1	1	1	1
R116	0.35	1	0.3	1	0	0
R117	0	1	1	1	0	1
R118	0.75	1	0.3	1	0	1
R119	0	0.35	1	0.6	1	1
R120	0.75	1	1	1	1	1
R121	0.75	0.35	1	0.6	0	0
R122	0	0.35	1	1	1	1
R123	0	1	0.3	1	0	0
R125	0.35	1	1	1	1	1
R126	0.35	1	0.3	0.6	0	0
R127	0.35	1	0.3	1	0	0
R128	0.35	1	1	0.6	1	1
R129	0.35	1	1	0.6	1	1
R130	0.35	1	1	0.6	1	1
R134	0	1	0.3	1	1	1
R135	0.75	1	0.3	1	0	0
R136	0.75	1	0.3	1	1	1
R137	0.75	1	0.3	1	0	0
R138	0.35	1	1	1	1	1
R139	0	1	0.3	1	0	0
R140	1	0.35	0.3	1	0	0

7.3. Prilog A-3

U ovome prilogu nalaze se normalizirani podaci za smjer menadžmenta.

	Evidencija	Zaposleni	Prijava HZMO	Intervencija	Radno Mjesto	Klasa
M1	0	0.35	0.3	1	1	0
M2	0.75	0.35	1	0.6	1	1
M3	0.35	1	1	1	0	1
M4	0.35	1	1	0.6	1	1
M5	0.75	0.75	1	1	0	0
M7	0.35	1	1	1	1	1
M8	0	0.35	0.3	1	0	0
M9	0.35	1	1	0.6	1	1
M10	0.75	0.35	0.3	1	0	0
M11	0.35	1	0	1	0	0
M12	0.75	0.35	0.3	0	0	0
M14	0.75	0.35	1	0.6	1	1
M15	0.35	1	1	1	1	1
M16	0.35	1	1	0.6	1	1
M17	0.75	0.75	1	0	1	1
M18	0.35	1	0.3	1	0	0
M19	0.35	1	0.3	1	0	0
M20	0.35	1	0.3	1	0	0
M21	0.75	0.35	0.3	1	0	0
M22	0.35	1	0.3	1	1	1
M23	0.75	0.35	0.3	0	0	0
M24	0.75	0.35	1	0.6	0	0
M25	0.35	1	1	1	0	1
M26	0.35	1	0	1	0	0
M27	0.35	1	1	0.6	1	1
M28	0.35	1	1	1	0	1
M29	0.35	1	1	1	1	1
M30	0.35	1	1	1	1	1
M33	0.35	1	1	1	0	1
M34	0.75	0.35	1	0.6	0	1
M35	0.35	1	1	0.6	1	1
M36	0.35	1	1	1	1	1
M37	0	1	0.3	1	0	0
M38	0.35	1	1	0.6	1	1
M39	0.35	1	1	1	1	1
M40	0.35	1	1	1	0	0
M41	0.75	0.35	1	0.6	0	1

M42	0	0.35	1	1	0	0
M43	0	0.35	1	1	0	0
M44	0.35	1	0.3	0	0	0
M45	0.75	0.35	0.3	1	0	0
M46	0.75	0.35	1	0.6	1	1
M47	0.35	1	1	1	1	1
M48	0.35	1	1	1	1	1
M49	0.35	1	0.3	1	0	0
M50	0.35	1	0.3	1	0	0
M51	0.35	1	1	1	1	1
M52	0.35	1	1	1	1	1
M53	0.35	1	1	1	0	1
M54	0	1	0	1	0	0
M55	0.75	0.35	0.3	1	0	0
M56	0.35	1	0.3	1	1	1
M57	0.35	1	0.3	1	1	0
M58	0.35	1	0.3	0.6	1	0
M59	0.35	0.75	1	1	0	0
M60	0.75	0.35	0.3	1	0	0
M62	0.75	0.35	0.3	1	0	0
M63	0	0.35	0	1	0	0
M64	0.35	1	1	0.6	1	1
M65	0.75	0.35	0	1	0	0
M67	0.75	0.75	1	0.6	1	1
M68	0.35	1	1	0.6	1	1
M69	0.35	1	1	0.6	1	1
M70	0.35	1	1	1	1	1
M71	0	0.35	1	0.6	0	0
M73	0.35	1	1	0.6	0	1
M74	0.35	1	1	0.6	0	1
M76	0.35	1	0.3	1	0	0
M78	0.35	1	1	0.6	1	1
M81	0.35	1	1	0.6	1	1
M82	0.35	1	1	1	0	0
M83	0	0.35	0	1	0	0
M85	0.35	1	0.3	1	0	0
M86	0	0.35	0	1	0	0
M87	0.35	1	0.3	0.6	0	0
M88	0.35	1	1	0.6	1	1
M89	0.35	1	0.3	1	0	0
M91	0.35	1	1	0.6	0	1
M92	0.35	1	0.3	1	0	0
M93	0	0.35	1	1	1	1

M94	0.35	1	1	1	0	1
M95	0.35	1	1	0.6	1	1
M97	0.35	1	0.3	1	0	0
M98	0.35	1	0.3	1	0	0
M99	0	0.35	1	0.6	1	0
M100	0.75	0.35	1	0	1	1
M101	0.35	1	1	0.6	1	1
M102	0.35	1	0.3	0	0	0
M103	0.35	1	1	0.6	0	0
M104	0	0.35	1	0.6	1	0
M105	0.35	1	0.3	1	0	0
M106	0.75	0.35	1	1	1	1
M107	0	0.35	0.3	1	0	0
M108	0.75	0.35	1	1	0	1
M109	0.35	1	0.3	1	0	1
M110	0.35	1	1	0.6	0	1
M111	0.75	0.35	1	0.6	1	1
M113	0.35	1	1	1	1	1
M115	0	0.75	0.3	1	0	0
M116	0.35	0.75	1	0.6	0	0
M117	0.35	1	1	0.6	0	1
M118	0.35	1	1	1	1	1
M119	0.75	0.75	1	0.6	1	1
M120	0.35	1	1	0.6	0	1
M121	0.35	1	1	0.6	1	1
M122	1	0	0	0	0	0
M123	1	0	0	0	0	0
M124	0.35	1	1	1	0	1
M126	0.35	1	1	0.6	0	1
M127	0.35	1	0.3	1	0	0
M129	1	0	0	0	0	0
M130	0.35	1	1	0.6	0	1
M131	0.35	1	1	0.6	0	1
M132	0.35	1	1	0.6	0	0
M133	0.35	1	1	0.6	1	1
M134	0.35	1	1	0.6	1	1
M135	0.35	1	0.3	1	0	0
M137	0.35	1	0.3	1	0	0
M138	0.35	1	0.3	1	0	0
M139	0.35	1	1	0.6	1	1
M140	0.35	1	1	0.6	1	1
M141	1	0.35	1	1	0	0
M142	1	0	0	0	0	0

M143	0.35	1	1	1	1	1
M144	0.35	1	1	1	1	1
M145	0.75	1	1	1	1	1
M146	0.75	0.35	1	0.6	0	1
M147	0.35	1	1	1	0	1
M148	0	1	0.3	0	0	0
M149	0	0.35	0.3	0.6	0	0
M150	0.35	1	1	1	0	1
M151	0.75	1	1	1	0	0
M152	0.35	1	1	0.6	0	1
M153	0.75	1	1	0.6	0	1
M154	0.75	1	1	1	0	1
M155	0	0.35	1	1	0	1
M156	0.75	0.75	1	0.6	0	1
M157	0.75	1	0.3	1	0	1
M158	0	1	1	1	0	1
M159	0.35	1	1	1	0	1
M160	0.75	1	0.3	1	0	1
M161	0.35	1	1	0.6	1	1
M162	0.35	1	1	0.6	1	1
M163	0.35	1	1	0.6	1	1
M164	0.75	1	1	1	1	1
M165	0	0.35	1	0.6	1	1
M166	0.35	0.75	1	0.6	0	1
M167	0.75	1	1	1	0	1
M168	0.75	0.35	1	0.6	0	1
M169	1	0.35	1	1	0	1
M170	0.75	0	0.3	1	0	1
M171	0.35	1	1	0.6	1	1
M172	0.35	1	0.3	1	1	1
M173	0.35	1	1	1	0	1
M174	0.35	1	1	1	1	1
M175	0.35	0	0	0	0	0
M176	0.35	0.35	1	0.6	0	0
M178	0.35	1	0.3	0	0	0
M179	0.75	1	0.3	1	0	0
M180	0.35	1	1	0.6	1	1
M181	0.75	0.35	1	0.6	1	1
M182	0.35	1	0.3	1	0	0
M183	0.35	1	1	0.6	1	1
M184	0.35	1	1	0.6	1	1
M185	0.75	0.35	1	0.6	1	1
M186	0.75	0.35	1	0.6	1	1

M187	0.35	1	0.3	1	0	0
M189	0.75	1	0.3	1	0	0
M190	0	1	0.3	1	0	0
M192	0	0	0.3	1	0	0
M193	1	0.35	0.3	1	1	1
M194	0.75	1	1	1	0	1
M195	0.75	1	0.3	1	0	0
M196	0	1	0.3	1	1	0
M197	0	1	0.3	1	1	0
M198	0.75	0.35	1	0.6	1	1
M199	0.75	1	0	0	0	0
M200	0	1	0.3	1	0	0
M201	0	1	0.3	1	1	0
M202	0	0.35	1	1	0	0
M203	0.75	1	1	1	0	0
M204	0.35	1	1	1	0	0
M206	0	1	0.3	1	0	0
M207	0.75	0.35	1	0.6	1	1
M208	0	0.35	0.3	1	0	0
M209	0.75	0.35	0.3	0.6	0	0
M210	0.75	1	0	1	0	0
M211	0.75	1	0	1	0	0
M212	0.75	1	0	1	0	0
M213	0	0.35	0	1	1	0
M214	0.75	0.35	1	1	0	1
M215	0.75	1	0.3	1	0	1
M216	0.35	1	0.3	1	0	0
M217	0.75	1	0	1	0	0
M219	0.75	0.35	1	0.6	1	1
M220	0.35	1	1	0.6	0	1
M221	0	0.35	1	1	0	0
M222	0.35	1	1	1	1	1
M223	0.35	1	0.3	0.6	1	1
M224	0.75	1	0	1	0	0
M225	0	0.35	0	1	0	0
M226	0	0.35	0.3	1	0	0
M227	0.75	1	0	1	0	0
M228	0.75	1	0	1	0	0
M229	0.75	1	0	1	0	0
M230	0.75	1	0	1	0	0
M231	0.75	1	0	1	0	0
M232	0.35	1	1	0.6	1	1
M233	0.35	1	1	0.6	1	1

M234	0.75	0.35	0.3	0.6	0	0
M235	0.35	1	1	0.6	1	1
M236	0.35	1	1	0.6	1	1
M237	0.35	0	0	0	0	0
M238	0.75	1	0	1	0	0
M239	0.35	1	1	0.6	1	1
M240	0.75	1	0.3	1	0	0
M241	0.75	1	0.3	1	0	1
M242	0	0.35	0.3	1	0	0
M243	0.75	1	0.3	1	0	1
M244	0	0.35	0.3	1	0	0
M245	0.75	1	0.3	1	0	0
M246	0.75	0.35	0	1	0	0
M247	0.75	1	0.3	1	0	0
M248	0.75	1	1	1	0	1
M249	0	0.35	0	1	0	0
M250	0.75	1	0.3	1	0	1
M251	0.75	1	0.3	1	0	1
M252	0.75	1	0.3	1	0	1
M253	0	1	1	1	0	1
M254	0.75	1	0.3	1	0	1
M255	0.75	1	1	1	0	1
M256	0.75	0.35	1	0.6	0	1
M257	0.75	1	0.3	0	0	1
M258	0.75	1	1	0.6	1	1
M259	0	0.35	0	0	0	0
M260	0	1	0.3	1	0	0
M261	0.75	0.35	1	0.6	0	0
M262	0.75	1	1	1	0	1
M263	0	0.35	0	1	0	0
M264	0.35	1	1	0.6	0	1
M265	0.75	1	0.3	1	0	1
M266	0.75	1	0.3	1	0	1
M267	0.75	1	0.3	0.6	0	0
M268	0	0.35	1	1	0	1
M269	0	0.35	0	1	0	0
M271	0.35	1	1	0.6	1	1
M272	0.75	1	1	1	0	1
M273	0.75	1	0.3	1	0	0
M274	0.75	1	0.3	1	0	0
M275	0	1	1	1	1	1
M277	0.35	1	1	1	0	1
M280	0.75	1	0.3	1	0	0

M281	0.35	1	1	1	1	1
M284	0.35	1	1	1	0	1
M285	0	0.35	0	1	0	0
M287	0.75	1	0	1	0	0
M288	0	0.35	0.3	1	0	0
M289	0	0.35	0	1	0	0
M290	1	0	0	0	0	0
M291	0.35	1	1	0.6	1	1
M292	1	0	0	0	0	0
M293	0.35	1	0	0.6	0	0
M294	0	1	0.3	1	1	0
M295	0.35	1	1	0.6	0	1
M297	0.75	1	0.3	1	0	0
M298	0.75	1	0	1	0	0
M299	0	1	0.3	1	0	0